

**LAPORAN TUGAS
METODOLOGI PENELITIAN**

Tugas – 5



Disusun Oleh :

Ghoffar Abdul Ja'far - 2341720035/TI3H

**JURUSAN TEKNOLOGI INFORMASI
POLITEKNIK NEGERI MALANG
2025/2026**

Pengembangan Model Computer Vision dan Data Engineering untuk Deteksi dan Klasifikasi Otomatis Objek Visual

1. Tabel SOTA (State of The Art)

Penulis (Tahun)	Judul	Metode	Dataset / Objek	Hasil	Keterbatasan / GAP
Archana & Jeevaraj (2024)	Deep Learning Models for Digital Image Processing: A Review	Studi literatur CNN dan DNN untuk pengolahan citra.	60+ publikasi (2018–2023)	Mengidentifikasi perkembangan cepat model CNN & Transformer pada deteksi dan segmentasi.	Tidak ada eksperimen empiris; tidak fokus pada integrasi model ringan untuk edge devices.
Xu et al. (2023)	A Comprehensive Survey of Image Augmentation Techniques for Deep Learning	Analisis 40+ teknik augmentasi data.	Dataset ImageNet, CIFAR-10, COCO	Mengelompokkan 40+ teknik augmentasi yang meningkatkan robustnes model hingga 10–20%.	Belum ada kajian implementasi untuk domain industrial atau realtime object detection.
He & Garcia (2009)	Learning from Imbalanced Data	Analisis algoritma sampling dan cost-sensitive learning.	Synthetic & real-world datasets	Menunjukkan SMOTE dan cost-sensitive learning sebagai solusi terbaik untuk data tidak seimbang.	Pendekatan belum mempertimbangkan deep learning modern seperti CNN/Transformer.
Hendrawati & Pravitasari (2025)	Real-time Emotion Recognition Using MobileNetV2 Architecture	CNN ringan untuk klasifikasi ekspresi wajah.	Dataset FER-2013	Akurasi 89.7% dan latency rendah (20 fps).	Model belum dioptimalkan untuk kondisi pencahayaan ekstrem; terbatas pada dataset wajah umum.
Farokhah & Riska (2024)	Analysis and Development of Eight Deep Learning Architectures for Classification of Mushrooms	Perbandingan 8 arsitektur CNN (ResNet, MobileNet, EfficientNet).	Dataset Mushroom Image	Model terbaik (EfficientNetB0) mencapai akurasi 96.3%.	Belum diuji pada domain lain seperti deteksi objek bergerak atau integrasi data pipeline.

2. Analisis GAP Penelitian:

Bidang computer vision dan data engineering berkembang pesat, namun sebagian besar penelitian masih fokus pada aspek model tunggal. Belum banyak penelitian yang mengintegrasikan augmentasi data, penyeimbangan dataset, dan arsitektur lightweight CNN dalam pipeline end-to-end. Penelitian nasional menegaskan potensi CNN ringan seperti MobileNetV2 dan EfficientNet, namun belum ada yang menghubungkan performa dengan teknik data balancing atau pipeline otomatis. Oleh karena itu, gap utama terletak pada integrasi penuh antara data engineering dan computer vision dalam sistem edge computing real-time.

3. Novelty

Tiga aspek kebaruan utama dari penelitian yang akan dilakukan:

- **Integrasi Data Engineering dan Computer Vision**
Penelitian menggabungkan proses *data augmentation*, *balancing*, dan *lightweight CNN*

deployment dalam satu pipeline otomatis, memperluas pendekatan yang selama ini terpisah.

- **Optimisasi Edge AI untuk Deteksi Real-Time**
Mengembangkan model berbasis **MobileNetV2 / EfficientNet** yang diadaptasi dengan *quantization* dan *pruning* agar efisien dijalankan pada perangkat tepi (IoT camera, Raspberry Pi).
- **Hybrid Improvement Framework**
Menyatukan teknik augmentasi (dari Xu et al., 2023) dan penyeimbangan data (He & Garcia, 2009) dalam pelatihan CNN modern guna mengatasi masalah overfitting dan data imbalance di dataset citra industri.

4. Kontribusi

- a. Kontribusi Teoritis:
 - Memperluas domain aplikasi deep learning ke integrasi data engineering.
 - Memberikan benchmark empiris performa CNN ringan untuk real-time detection.
 - Menyediakan framework pipeline adaptif untuk riset AI Engineering.
- b. Kontribusi Praktis:
 - Meningkatkan efisiensi deteksi di lingkungan industri dan pertanian.
 - Mendukung transformasi digital UMKM melalui solusi AI ringan.
 - Mendorong penerapan edge computing untuk sistem lokal mandiri

Reference

Archana, R., & Jeevaraj, P. S. E. (2024). Deep learning models for digital image processing: A review. *Artificial Intelligence Review*, 57(1). <https://doi.org/10.1007/s10462-023-10631-z>

Xu, M., Yoon, S., Fuentes, A., & Park, D. S. (2023). A comprehensive survey of image augmentation techniques for deep learning. *Pattern Recognition*, 137, 109347. <https://doi.org/10.1016/j.patcog.2023.109347>

He, H., & Garcia, E. A. (2009). Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284. <https://doi.org/10.1109/TKDE.2008.239>

Hendrawati, T., & Apriliyanti Pravitasari, A. (2025). Real-time emotion recognition using the MobileNetV2 architecture. *Jurnal RESTI*, 9(4), 714–720. <https://doi.org/10.29207/resti.v9i4.6158>

Farokhah, L., & Riska, S. Y. (2024). Analysis and development of eight deep learning architectures for the classification of mushrooms. *Jurnal RESTI*, 8(1), 142–149. <https://doi.org/10.29207/resti.v8i1.5498>